

# 面向欺诈通话检测的 supervised 模型构建 与社会工程诱导鲁棒性分析

——基于 Fraud-R1 思路的多策略语义改写攻击研究

机器学习课程大作业

2026 年 6 月

## Abstract

电信网络诈骗已成为危害最广的社会犯罪形态之一,而欺诈通话作为其主要载体,亟需高效的自动化检测手段。本文基于课程提供的中文通话互动数据集(共 16,189 通对话),构建并系统对比了五类 supervised 欺诈通话分类模型,涵盖传统机器学习(TF-IDF + 逻辑回归/SVM/随机森林/朴素贝叶斯)、深度学习(TextCNN、BiLSTM+ 注意力)与预训练语言模型(中文 RoBERTa、MacBERT)。实验表明,各模型在原始**是否欺诈二分类**任务上均取得接近完美的性能(F1 介于 0.999~1.000),揭示原始数据中欺诈词汇线索高度显著;为提供更具区分度的评测,本文进一步构建了**欺诈类型 7 分类**任务,其最优 Macro-F1 仅约 0.75,任务难度显著提升并有效拉开了模型差距。在鲁棒性评估上,本文采用两类互补的对抗攻击:其一,参考 Fraud-R1 [1] 提出的多轮增强诱导思路,借助大语言模型设计**诱导增强**(信任建立、紧迫感、情感操纵、权威伪装、语义改写)与**对抗规避**(关键词规避、良性伪装、谐音隐语)两组共八种语义级改写策略;其二,实现经典的 TextFooler [2] 自动化词级对抗攻击(中文离线适配),从词级扰动维度交叉验证。两类攻击在不重新训练的前提下评估各分类器的鲁棒性,得到**高度一致**的核心发现:以**提升对人的说服力为目标**的诱导增强策略几乎不降低检测器性能(甚至因关键词密度上升而更易检出),而以**隐藏欺诈特征为目标**的对抗规避/词级替换才能显著**击穿检测器**——关键词规避使 BiLSTM 的欺诈检出率下降达 13.5 个百分点(经 bootstrap 检验统计显著),TextFooler 仅替换 8.6% 的词即可攻陷 88.5% 的 BiLSTM 样本。模型鲁棒性呈明显分层:深层语义建模的预训练模型(MacBERT、RoBERTa)远比浅层模型稳健(TextFooler 攻击下 RoBERTa 的 ASR 仅 4.5%,而 BiLSTM 高达 88.5%)。本研究揭示了社会工程诱导与文本检测器脆弱面的正交性,为构建鲁棒的反诈检测系统提供了实证依据。代码与数据见 GitHub 仓库。

**关键词:** 欺诈通话检测; 文本分类; 预训练语言模型; 社会工程攻击; 对抗鲁棒性; Fraud-R1

## 1 研究背景与问题意义

### 1.1 电信诈骗与欺诈通话的现状

电信网络诈骗是指犯罪分子通过电话、短信、互联网等远程通信手段,编造虚假信息、设置骗局,对受害人实施远程非接触式诈骗,诱使其向犯罪分子转账或泄露敏感信息的犯罪行为。近年来,随着移动通信与互联网的普及,电信诈骗呈现出**规模化、产业化、智能化**的发展态势。据公安部门统计,电信网络诈骗已连续多年位居刑事案件发案量首位,造成的经济损失高达数千亿元,且受害群体覆盖各年龄段、各职业层次。

在各类电信诈骗中,**欺诈通话**(诈骗电话)是最直接、最具迷惑性的实施方式。与短信、邮件等异步媒介不同,通话具有**实时交互**的特性:诈骗分子能够根据受害者的即时反应动态调整话术,通过多轮对话逐步建立信任、制造压力、操纵情绪,最终诱导受害者完成转账或信息泄露。课程提供的数据集即为这种双向通话互动的真实写照,每通对话包含主叫方(left)与受话方(right)的多轮往复,并标注了欺诈类型(客服诈骗、银行诈骗、投资诈骗、钓鱼诈骗、彩票诈骗、绑架诈骗、身份盗窃等)。

欺诈通话的危害不仅在于其直接的经济损失,更在于其**演化速度快、对抗性强**的特点。诈骗剧本不断翻新,话术持续迭代,使得依赖固定规则或黑名单的传统拦截手段难以为继。因此,研究

基于内容理解的智能化欺诈通话检测方法, 对于保护人民财产安全、维护社会稳定具有重要的现实意义。

## 1.2 机器学习算法在诈骗检测中的应用

面对海量的通话与文本数据, 人工审核显然无法满足实时性与规模化的要求, **机器学习**因而成为诈骗检测的核心技术路径。其应用大致经历了三个阶段的演进:

(1) **基于特征工程的传统机器学习阶段**。早期方法将诈骗检测建模为文本分类问题, 通过词袋模型 (Bag-of-Words)、TF-IDF 等手段将文本转化为稀疏特征向量, 再输入支持向量机 (SVM)、逻辑回归、朴素贝叶斯、随机森林等分类器进行判别 [3, 4]。这类方法实现简单、可解释性强、训练高效, 在关键词区分度高的场景下表现优异, 但严重依赖人工特征设计, 难以捕捉深层语义与上下文依赖。

(2) **基于深度学习的表示学习阶段**。卷积神经网络 (TextCNN)、循环神经网络 (LSTM/GRU) 及其注意力增强变体能够自动学习文本的局部 n-gram 模式与长程依赖, 在垃圾短信、钓鱼文本、诈骗通话转写等任务上取得了优于传统方法的效果 [5]。深度模型摆脱了人工特征的束缚, 但通常需要较大的标注数据, 且对分布外样本的泛化能力有限。

(3) **基于预训练语言模型的迁移学习阶段**。以 BERT [6]、RoBERTa [7] 为代表的预训练语言模型通过在大规模无标注语料上进行自监督预训练, 习得了丰富的语言知识与语义表示, 再通过下游任务微调即可在小样本上取得优异性能。针对中文场景, 哈工大讯飞联合实验室提出的 MacBERT [8] 采用相似词替换的掩码策略, 进一步缓解了预训练与微调阶段的不一致问题。预训练模型已成为当前文本型诈骗检测的主流方案 [9]。

## 1.3 社会工程攻击的特点

诈骗的本质并非技术入侵, 而是**对人性弱点的操纵**——这正是社会工程攻击 (Social Engineering Attack) 的核心。社会工程攻击指攻击者利用心理学原理, 通过欺骗、诱导、伪装等手段操纵目标对象, 使其主动泄露信息或执行有害操作。在欺诈通话场景中, 社会工程攻击通常综合运用以下几类心理策略:

- **权威与可信度建立 (Authority & Credibility)**: 冒充公检法、银行、运营商、知名平台等权威机构, 辅以工号、备案编号、专业术语, 降低受害者的戒备。
- **紧迫感制造 (Urgency)**: 编造“账户即将冻结”“限时处理”“逾期影响征信”等时间压力, 迫使受害者来不及理性思考即采取行动。
- **情感操纵 (Emotional Manipulation)**: 利用亲情 (家人出事)、恐惧 (涉嫌犯罪)、贪婪 (高额回报)、同情等情绪, 瓦解受害者的心理防线。
- **互惠与承诺 (Reciprocity & Commitment)**: 先施以小恩小惠 (退款、优惠券) 再提出要求, 利用人的互惠心理。

值得注意的是, 课程数据集为每通对话标注了五个**互动策略**维度 (事实真实性、完整性、清晰度、相关性、个性化), 这些维度恰好刻画了诈骗话术在信息呈现层面的特征, 与上述社会工程策略相互呼应。Fraud-R1 [1] 进一步将社会工程策略系统化为可操作的多轮增强流程, 而 Zeng 等 [10] 则从说服理论出发, 构建了多达 40 类的说服技巧分类法用于挑战 AI 安全, 二者共同表明: **社会工程策略是可以被形式化、自动化生成的**, 这为本文设计语义改写攻击提供了方法论基础。

## 1.4 传统诈骗检测方法的局限性

尽管机器学习方法在诈骗检测中取得了显著成效, 但现有方法仍存在以下局限:

**第一, 对表层词汇线索的过度依赖**。无论是 TF-IDF 还是深度模型, 在标注数据上学到的判别依据往往是“链接”“转账”“验证码”“冻结”等高频欺诈关键词。当数据集的欺诈样本与正常样本在这些关键词上高度可分时, 模型能轻易达到接近完美的准确率, 但这种性能是**脆弱**的——一旦攻击者刻意规避或替换这些关键词, 模型性能将急剧下降。本文的实验将定量揭示这一现象。

**第二, 对抗鲁棒性不足。**大量研究表明, 文本分类器极易受到对抗样本的攻击。TextFooler [2]、BERT-ATTACK [11] 等工作证明, 即便是强大的 BERT, 通过同义词替换等微小扰动即可被显著攻陷。在真实诈骗对抗中, 犯罪分子使用谐音字、拆字、隐语等手段规避关键词过滤已是常态, 这对检测系统的鲁棒性提出了严峻挑战。

**第三, 评测范式的静态性。**传统检测方法的评估通常局限于固定的测试集, 无法反映真实世界中攻防对抗的动态性。攻击者会主动适应检测系统, 而静态评测会系统性地高估模型的实际防护能力。

**第四, 缺乏对社会工程维度的考量。**现有方法多关注“文本是否含诈骗特征”, 却很少考察“不同诱导策略如何影响检测难度”。理解社会工程策略与检测器性能之间的关系, 对于设计真正鲁棒的反诈系统至关重要。

## 1.5 Fraud-R1 提出的研究问题及意义

Fraud-R1 [1](*A Multi-Round Benchmark for Assessing the Robustness of LLM Against Augmented Fraud and Phishing Inducements*, ACL 2025 Findings) 针对上述局限, 提出了一个系统化评估大语言模型 (LLM) 抗欺诈骗诱导鲁棒性的多轮基准。其核心研究问题是: **当面对经过社会工程策略增强的、逐步升级的欺诈骗诱导时, LLM 能否持续保持防御, 拒绝被诱导?**

Fraud-R1 的主要贡献与创新在于:

1. **多轮增强诱导流程。**它将欺诈骗诱导沿“基础诱导 → 建立可信度 → 制造紧迫感 → 情感诉求”的层级逐步增强, 模拟真实诈骗中话术不断升级、压力层层加码的过程。
2. **双情境评测设置。**设计了“乐于助人的助手 (Helpful Assistant)”与“角色扮演 (Role-play)”两种情境, 分别考察模型在常规交互与被赋予特定身份时的鲁棒性差异。
3. **大规模双语基准。**构建了涵盖 5 大类欺诈骗、共 8,564 条样本的中英双语数据集, 并提出防御成功率 (Defense Success Rate, DSR) 作为核心评测指标。

Fraud-R1 的意义在于: 它首次将“社会工程诱导的逐步增强”形式化为一个可复现的评测范式, 从**动态对抗**而非静态分类的视角审视安全模型的鲁棒性。

本文受 Fraud-R1 启发, 但将其思路迁移至一个不同但密切相关的任务上: Fraud-R1 评测的是生成式 LLM 是否会被诱导而“上当”(防御视角), 而本文评测的是判别式分类器在面对经诱导/改写的欺诈骗文本时能否依然准确识别 (检测视角)。我们借鉴 Fraud-R1 的多策略增强思想, 设计了针对检测器的语义改写攻击, 从而回答一个本课程更核心的问题: 社会工程诱导策略究竟如何影响监督学习欺诈骗检测系统的性能?

## 2 相关工作

### 2.1 文本分类与诈骗检测

将诈骗检测建模为文本分类任务是该领域的主流范式。在垃圾短信、钓鱼邮件、诈骗电话等场景下, 研究者广泛采用从传统机器学习到深度学习的多种方法。Krishnan [3] 系统对比了 SVM、逻辑回归、随机森林等传统模型与 Transformer 模型在欺骗性文本分类上的表现, 为方法谱系提供了对照。在电信领域, Natarajan et al. [5] 直接在电话通话转写文本上应用深度学习进行骚扰检测, 验证了通话文本的可分类性, 与本文任务高度契合。针对中文电信诈骗, CCL23-Eval Task 6 [12] 采用两阶段训练与任务内预训练框架进行诈骗案件分类, 是中文场景的代表性工作。这类方法的**优点**是任务定义清晰、技术成熟、易于落地; **局限**在于多聚焦于“干净”测试集上的分类精度, 缺乏对抗场景下的鲁棒性考量。

### 2.2 基于机器学习与深度学习的诈骗识别

在具体模型层面, Achary et al. [4] 并行评估了 LSTM、CNN、SVM 三类经典模型在钓鱼检测中的性能, 覆盖了本文采用的多条基线。随着预训练模型的兴起, BERT [6] 及其优化版 RoBERTa [7] 成为强基线; Ibrahim and Elhafiz [9] 直接微调 BERT 与 RoBERTa 进行钓鱼邮件检测并比较二



者效果。面向中文,MacBERT [8] 通过相似词掩码策略改进预训练,在多项中文任务上表现优异。这些方法的**优点**是借助预训练知识显著提升了语义理解能力,小样本下即可取得高精度;**局限**在于:其一,模型创新多为应用性微调;其二,如后文实验所示,即便是强大的预训练模型,在面对刻意规避关键词的对抗改写时仍会出现性能滑坡。此外,亦有研究 [13] 尝试将对抗训练与预训练模型结合以提升鲁棒性,为防御端提供了思路。

## 2.3 大语言模型在安全评测中的应用

大语言模型的崛起为安全评测带来了双重角色:既是检测工具,也是评测对象。在**检测工具**方面,Patel et al. [14] 评估了多个 LLM 作为零样本钓鱼识别器的有效性,Ding and Zhou [15] 设计多角色多层次提示策略驱动 LLM 进行电信诈骗检测,Shen et al. [16] 则探索了基于 LLM 的实时电话诈骗检测系统。在**评测对象**方面,PromptRobust [17] 构建了字符、词、句、语义多层次的对抗提示扰动以评估 LLM 鲁棒性;AdvGLUE [18] 提供了多任务对抗鲁棒性基准。这些工作的**优点**是揭示了 LLM 在安全场景下的能力边界与脆弱性;**局限**在于:基于提示工程的检测对提示高度敏感且成本较高,而通用鲁棒性基准的扰动多为词级,缺乏面向诈骗的社会工程语义级改写。Fraud-R1 [1] 正是为填补这一空白而提出。

## 2.4 社会工程攻击与文本对抗改写

本文的方法论直接承接对抗样本与社会工程改写两条研究脉络。在**对抗样本**方面,TextFooler [2](AAAI 2020) 通过重要词定位与同义词替换攻陷 BERT,BERT-ATTACK [11](EMNLP 2020) 利用掩码语言模型生成更流畅的对抗替换,TextAttack [19] 则提供了统一的攻击与对抗训练框架。这些工作证明了文本分类器在词级扰动下的普遍脆弱性,但其扰动停留在**低层语义**,与真实诈骗中的话术改写不同。在**社会工程/说服改写**方面,Zeng 等 [10](ACL 2024) 从说服理论出发将有害请求改写为有说服力的对抗提示,是 Fraud-R1 类社工诱导的理论源头;Cheng et al. [20] 提出通用对抗改写攻击以规避检测器;Ma et al. [21] 则构建了面向电信诈骗的音频-文本数据集。这些工作的**优点**是将高层的社会工程/说服策略形式化为可自动生成的改写操作,贴近真实对抗;**局限**在于多面向 LLM 越狱或 AI 文本检测,鲜有针对”判别式欺诈通话检测器”的系统性鲁棒性评估——这正是本文的切入点。

## 2.5 相关工作小结

综上,现有研究在欺诈检测的建模与对抗鲁棒性的评测两条线上均有丰富积累,但二者的交叉地带——**社会工程诱导策略对监督式欺诈通话检测器的差异化影响**——尚未被充分探讨。本文的工作正是在这一交叉点上:一方面构建并横向对比多类检测模型(承接 §2.1~§2.2),另一方面借鉴 Fraud-R1 的多策略增强思想(承接 §2.3~§2.4)设计语义改写攻击,定量刻画不同诱导/规避策略对检测性能的影响。

# 3 方法

本节分两部分:§3.1 阐述欺诈通话分类模型的构建(对应任务 a,并在 §4.5 扩展到更难的欺诈类型多分类),§3.2 解读 Fraud-R1 方法并说明本文借鉴其思想设计的语义改写攻击,以及作为交叉验证的 TextFooler 自动化词级攻击(对应任务 b)。

## 3.1 欺诈通话分类模型

### 3.1.1 任务定义与输入表示

给定一通通话对话  $x$ (由主叫方 `left` 与受话方 `right` 的多轮文本拼接而成),欺诈通话检测的目标是学习一个分类函数  $f: x \mapsto y$ , 其中  $y \in \{0, 1\}$ ,  $y = 1$  表示欺诈通话,  $y = 0$  表示正常通话。这是一个**二分类**问题。形式化地,模型输出欺诈概率  $p(y=1 | x)$ , 并以 0.5 为阈值给出预测标签。

在**输入表示**上,本文针对不同模型族采用相应的文本编码方式:

- **传统机器学习模型**: 先用 jieba 对中文对话分词, 再以 TF-IDF 加权的 1~2 元词袋构建稀疏特征向量 (最大 50,000 维, min\_df=2, 采用次线性词频缩放)。
- **深度学习模型**: 采用字符级编码, 构建字表 (最小词频 2, 最大 30,000), 将对话截断/补齐至 400 字符的整数序列, 经可训练的嵌入层映射为稠密向量。
- **预训练语言模型**: 采用 WordPiece 子词切分, 在序列首尾添加 [CLS]/[SEP] 标记, 截断至 256 个 token, 以 [CLS] 位置的隐状态作为整句语义表示。

### 3.1.2 模型结构

为全面对比不同复杂度模型的检测能力与鲁棒性, 本文构建了横跨三个技术代际、共五种代表性结构的模型谱系:

(1) **传统机器学习基线**。在 TF-IDF 特征之上, 分别训练逻辑回归、线性 SVM、随机森林与多项式朴素贝叶斯四种分类器。这类模型本质上是基于词汇统计线索进行线性或浅层判别。

(2) **深度学习模型**。TextCNN 使用多尺度一维卷积核 (窗口 2/3/4/5, 各 128 个) 提取局部 n-gram 特征, 经最大池化后拼接, 再由全连接层分类; BiLSTM+Attention 使用双层双向 LSTM (隐层维度 128) 建模序列上下文, 并通过加性注意力对各时刻隐状态加权聚合, 以突出关键话术片段。

(3) **预训练语言模型**。采用中文 RoBERTa (chinese-roberta-wwm-ext, 全词掩码) 与 MacBERT (chinese-macbert-base)。二者均为 12 层 Transformer 编码器, 在大规模中文语料上预训练, 本文在其顶端接入分类头进行微调。预训练模型的核心优势在于具备深层语义理解能力, 而非仅依赖表层词形。图 1 给出了以预训练模型为例的整体结构示意图。




图 1: 欺诈通话分类模型的统一框架。不同模型族在”编码器”与”表示聚合”环节采用各自的结构, 但共享”文本输入 → 表示学习 → 二分类输出”的整体流程。

### 3.1.3 训练方法

所有模型均在同一份训练数据上以监督方式训练, 采用交叉熵损失:

$$\mathcal{L} = -\frac{1}{N} \sum_{i=1}^N \left[ y_i \log p_i + (1 - y_i) \log(1 - p_i) \right], \quad (1)$$

其中  $p_i = p(y=1 | x_i)$ 。传统模型直接以 scikit-learn 求解 (逻辑回归  $C=4.0$ , SVM  $C=1.0$ , 随机森林 300 棵树)。深度模型使用 Adam 优化器 (学习率  $10^{-3}$ ), 训练 6 轮, 字符嵌入维度 128, Dropout 0.5。预训练模型使用 AdamW 优化器 (学习率  $2 \times 10^{-5}$ , 权重衰减 0.01), 线性预热加衰减的学习率调度, 混合精度训练 3 轮, 批大小 32。所有训练在单张 NVIDIA RTX 5090 GPU 上完成, 并以验证集 F1 选择最优检查点。训练流程如图 2 所示。




图 2: 欺诈通话分类模型的训练与评估流程。

## 3.2 Fraud-R1 方法解读与语义改写攻击设计

### 3.2.1 Fraud-R1 的研究目标

如 §1.5 所述, Fraud-R1 [1] 的研究目标是**系统评估大语言模型在面对逐步增强的欺诈与钓鱼诱导时的防御鲁棒性**。其关注的不是”模型能否识别一段文本是否为诈骗”,而是”当模型本身作为对话参与者、被诈骗话术层层诱导时,能否守住安全底线、拒绝配合”。这是一种**动态、多轮、对抗**的安全评测范式,与传统的静态分类评测形成鲜明对比。

### 3.2.2 多轮诱导策略设计

Fraud-R1 的核心机制是**诱导的逐级增强 (Level-up)**。它将一条基础欺诈请求沿以下层级逐步包装,使诱导强度递增:

1. **基础诱导 ( $D^0$ )**: 直接提出欺诈性请求,作为对照基线。
2. **建立可信度 ( $D^1$ )**: 注入背景细节、伪造官方身份或权威信息,使请求显得真实可信。
3. **制造紧迫感 ( $D^2$ )**: 叠加时间压力 (如”立即处理,否则账户冻结”),压缩受害者的理性思考空间。
4. **情感诉求 ( $D^3$ )**: 进一步诉诸恐惧、同情、贪婪等情绪,瓦解心理防线。

同时, Fraud-R1 在”乐于助人的助手”与”角色扮演”两种情境下评测,并以**防御成功率 (DSR)**——即模型成功拒绝诱导的样本比例——作为核心指标。

### 3.2.3 为什么该方法可能起作用或不起作用

**该方法之所以能够奏效**,根植于其对人类认知弱点的精准利用:可信度建立降低警觉、紧迫感抑制理性、情感诉求劫持决策,层层叠加形成”温水煮蛙”式的诱导,这与社会心理学中的说服理论 [10] 一脉相承。对于被诱导的 LLM 而言,多轮上下文的累积、角色扮演设定的代入,都会侵蚀其安全对齐,使其逐步”配合”。

**然而,该方法对本文研究的检测器却未必奏效**,原因在于评测视角的根本差异。Fraud-R1 攻击的是”被诱导的对话参与者 (人/LLM)”,而判别式检测器是一个**冷静的第三方观察者**:它不参与对话、不受情绪影响,只对文本特征进行判别。诱导增强策略 (可信度、紧迫感、情感) 在提升对人的说服力的同时,往往会**引入更多典型诈骗话术与关键词** (如”立即””冻结””验证””转账”),这反而**强化了检测器赖以判别的特征信号**。换言之,使一段话术对人更危险的修改,可能使其对检测器更易识别——这是社会工程诱导与文本检测脆弱面之间的**正交性**。本文的实验 (§4) 将定量验证这一假设。

### 3.2.4 本文的语义改写攻击设计

基于上述分析, 本文借鉴 Fraud-R1 的多策略增强思想, 设计了两组、共八种针对**检测器**的语义改写策略, 并借助大语言模型 (DeepSeek) 自动生成改写后的测试样本。所有改写均**严格保持原对话的欺诈意图与剧本不变**, 仅改变表达方式, 因此改写样本的真实标签仍为” 欺诈”。两组策略如表 1 所示。

表 1: 本文设计的两组语义改写策略 (均保持欺诈意图不变)

| 组别                          | 策略    | 改写目标 (对应 Fraud-R1 思想)                     |
|-----------------------------|-------|-------------------------------------------|
| <b>诱导增强组</b><br>(增强对人的说服力)  | 信任建立  | 强化权威身份、官方背景与专业话术, 提升可信度 ( $\approx D^1$ ) |
|                             | 紧迫感   | 叠加时间压力、后果警告, 迫使尽快行动 ( $\approx D^2$ )     |
|                             | 情感操纵  | 诉诸亲情、恐惧、同情等情绪, 瓦解防线 ( $\approx D^3$ )     |
|                             | 权威伪装  | 冒充公检法/银行/平台, 辅以编号术语                       |
|                             | 语义改写  | 多轮口语化重述, 增加寒暄铺垫, 自然化表达                    |
| <b>对抗规避组</b><br>(隐藏对检测器的特征) | 关键词规避 | 用委婉间接说法替换” 链接/转账/验证码” 等敏感词                |
|                             | 良性伪装  | 用大段正常业务寒暄包裹、稀释诈骗诱导部分                      |
|                             | 谐音隐语  | 用谐音字、拼音、拆字、黑话替代关键诈骗词                      |

诱导增强组直接对应 Fraud-R1 的  $D^1 \sim D^3$  增强层级, 旨在检验” 提升对人的诱导强度” 是否影响检测器; 对抗规避组则承接文本对抗攻击思路 [2, 11, 20], 旨在检验” 主动隐藏特征” 对检测器的真实威胁。这一对照设计使我们能够清晰区分” 对人有效” 与” 对检测器有效” 两类不同的攻击。

## 4 实验与结果分析

### 4.1 数据集与预处理

本文使用课程提供的中文通话互动数据集, 原始训练集 14,363 通、测试集 2,677 通对话。每条样本包含对话正文 (specific\_dialogue\_content)、互动策略 (interaction\_strategy)、通话类型 (call\_type)、是否欺诈 (is\_fraud) 与欺诈类型 (fraud\_type) 五个字段。预处理包括:

- 文本清洗:** 去除统一的” 音频内容:” 前缀与结尾的” \*\*” 噪声标记, 规范化连续空行。
- 标签补全与过滤:** 对 is\_fraud 缺失但 fraud\_type 存在的样本, 推断为欺诈; 对二者皆缺失或文本过短 ( $<10$  字) 的样本予以剔除。
- 数据划分:** 从清洗后的训练集中按标签分层划出 10% 作为验证集。

最终各划分规模如表 2 所示, 正负样本基本均衡 (欺诈占比约 54%)。图 3 展示了数据集的标签分布、对话长度分布、欺诈类型分布与互动策略-欺诈关系等统计特征。可以观察到, 欺诈通话以客服诈骗、银行诈骗、投资诈骗为主, 对话长度集中在 300~500 字符, 且” 相关性 (Relevance)” 是出现最频繁的互动策略标签。

表 2: 数据集划分规模

| 划分  | 总数     | 欺诈    | 正常    | 欺诈占比  |
|-----|--------|-------|-------|-------|
| 训练集 | 12,273 | 6,609 | 5,664 | 53.8% |
| 验证集 | 1,364  | 734   | 630   | 53.8% |
| 测试集 | 2,552  | 1,391 | 1,161 | 54.5% |






图 3: 数据集探索性分析。

## 4.2 评价指标

针对二分类任务, 本文采用四项标准指标: **准确率 (Accuracy)**、**精确率 (Precision)**、**召回率 (Recall)** 与 **F1 分数**。在鲁棒性实验中, 由于改写仅作用于欺诈样本, 我们进一步关注:

- **欺诈检出率 (Detection Rate, DR)**: 被正确识别为欺诈的样本比例, 等价于欺诈类召回率。检出率越高, 鲁棒性越强。借用 Fraud-R1 的术语, 检出率即检测器侧的**防御成功率 (DSR)**, 而检出率的下降量即**攻击成功率 (ASR)**。
- **平均欺诈置信度 (Mean Fraud Probability)**: 模型对欺诈类输出概率的均值。即便预测标签未翻转, 置信度的下降也揭示了决策边界被推近的”鲁棒性裂缝”。

## 4.3 欺诈通话分类模型性能 (任务 a)

表 3 与图 4a 报告了各模型在原始测试集上的分类性能。可以看到, **所有模型均取得了接近完美的检测效果**, F1 分数介于 0.999~1.000 之间, 其中逻辑回归、线性 SVM、TextCNN、MacBERT 并列最优 ( $F1 = 0.9996$ )。图 4b 的混淆矩阵进一步显示, 顶尖模型在 2,552 条测试样本上仅出现 1~3 个错误。



表 3: 各模型在原始测试集上的分类性能

| 类别    | 模型                 | 准确率    | 精确率    | 召回率    | F1            |
|-------|--------------------|--------|--------|--------|---------------|
| 传统 ML | 逻辑回归 (TF-IDF)      | 0.9996 | 0.9993 | 1.0000 | <b>0.9996</b> |
|       | 线性 SVM(TF-IDF)     | 0.9996 | 0.9993 | 1.0000 | <b>0.9996</b> |
|       | 随机森林 (TF-IDF)      | 0.9980 | 0.9964 | 1.0000 | 0.9982        |
|       | 朴素贝叶斯 (TF-IDF)     | 0.9976 | 0.9957 | 1.0000 | 0.9978        |
| 深度学习  | TextCNN            | 0.9996 | 0.9993 | 1.0000 | <b>0.9996</b> |
|       | BiLSTM + Attention | 0.9992 | 0.9993 | 0.9993 | 0.9993        |
| 预训练模型 | RoBERTa-wwm-ext    | 0.9988 | 0.9993 | 0.9986 | 0.9989        |
|       | MacBERT            | 0.9996 | 0.9993 | 1.0000 | <b>0.9996</b> |




图 4: 各模型在原始测试集上的分类表现。

**现象分析:** 如此一致且接近完美的性能, 看似令人振奋, 实则值得审慎追问其根因。为厘清这一点, 我们对数据集做了捷径诊断 (§4.4), 结论是: 高性能并非源于数据泄漏, 而是欺诈与正常通话在多个层面系统性可分——这种可分性在原始分布上稳固, 却未必能抵御针对性的对抗改写。基于综合性能, 我们选取覆盖三个代际的代表性模型进入鲁棒性评估。

#### 4.4 性能根因诊断: 捷径还是真学习?

近乎完美的分类性能常引发“模型是否只是利用了数据集捷径 (shortcut)”的质疑。我们从三方面诊断 (脚本 `src/data/shortcut_diagnosis.py`, 结果见表 4):

(1) **无数据泄漏。** 训练集 (含验证) 与测试集的对话完全重复数为 0, 排除了因样本泄漏导致的虚高; 但训练集内部存在 25.3% 的重复对话, 反映该数据集系合成/半合成构造。

(2) **任务并非平凡。** 我们构造一个仅凭“对话是否包含 12 个典型欺诈关键词 (点击/链接/验证码/转账/银行卡/冻结等)”判别的规则基线。该规则在测试集上仅取得  $F1 = 0.728$  (准确率 0.763), 远低于学习模型的 0.999——这说明单纯的关键词匹配不足以解释模型的高性能, 模型确实学到了关键词之外的判别信号 (如“配合”“为了您的安全”“现在就”等软性话术、对话结构与句式)。表 4 下半部分列出的逻辑回归高权重词亦印证: 除“链接”“点击”等硬关键词外, “投资”“贷款”“配合”“为了”等话术性词汇同样具备强判别力。

(3) **两类分布差距显著。** 欺诈通话含上述关键词的比例为 58.3%, 而正常通话仅 2.2%。关键词虽非充分线索, 但其在两类间的极端不均衡, 正是检测器易学、也易被对抗规避攻击针对的弱点。

表 4: 数据集捷径诊断结果

| 诊断项                                        | 结果             |
|--------------------------------------------|----------------|
| train/test 完全重复对话数                         | 0 / 2,552(无泄漏) |
| 训练集内部重复率                                   | 25.3%          |
| 仅关键词规则的测试集 F1                              | 0.728          |
| 仅关键词规则的测试集准确率                              | 0.763          |
| 学习模型最优 F1(对照)                              | 0.9996         |
| 欺诈通话含关键词比例                                 | 58.3%          |
| 正常通话含关键词比例                                 | 2.2%           |
| 逻辑回归高判别力词 (偏欺诈): 链接、投资、贷款、下载、配合、为了、安全、银行…… |                |
| 逻辑回归高判别力词 (偏正常): 预约、价格、小区、下午、明天、周末、客气……    |                |




图 5: 捷径诊断。左: 各欺诈关键词在欺诈/正常通话中的覆盖率 (差距悬殊但欺诈类覆盖仅约六成); 右: 仅关键词规则的 F1(0.728) 显著低于各学习模型, 说明模型学到了关键词之外的信号。

这一诊断对本文结论至关重要: 它表明检测器的高性能**部分**依赖关键词、**部分**依赖更深的话术特征。因此, 单纯移除关键词的对抗规避能削弱但未必彻底击溃强模型 (如 MacBERT), 而浅层模型因更依赖词频线索则受损严重——这与后续鲁棒性实验的分层结果完全吻合。

#### 4.5 从二分类到欺诈类型多分类: 一个更具挑战性的任务

§4.3 显示是否欺诈的二分类任务对所有模型都过于简单 ( $F1 \approx 1.000$ ), 难以拉开模型差距、检验真实的语义理解能力。为此, 我们在**欺诈样本子集**上构建一个更困难的**欺诈类型 7 分类**任务: 将每通诈骗电话进一步判定为客服诈骗、银行诈骗、投资诈骗、钓鱼诈骗、彩票诈骗、绑架诈骗、身份盗窃之一。该任务的难点在于: 其一, 类别**高度不平衡** (训练集客服诈骗 2,609 条, 身份盗窃仅 134 条, 相差近 20 倍); 其二, 部分类别**语义高度重叠** (如“客服诈骗”与“银行诈骗”均围绕账户、退款、身份核验展开), 仅凭表层关键词难以区分, 真正考验模型的深层语义辨析能力。

我们沿用三个代际的代表模型, 在欺诈样本 (训练 7,343 / 测试 1,391) 上重新训练并评估, 损失函数采用**类别加权交叉熵**以缓解不平衡。表 5 报告了准确率与宏平均/加权平均 F1。

表 5: 欺诈类型 7 分类性能 (对照二分类  $F1 \approx 1.000$ , 本任务显著更难)

| 类别    | 模型              | 准确率   | Macro-F1     | Weighted-F1 |
|-------|-----------------|-------|--------------|-------------|
| 传统 ML | 逻辑回归 (TF-IDF)   | 0.759 | 0.746        | 0.759       |
| 深度学习  | TextCNN(字符级)    | 0.647 | 0.664        | 0.636       |
| 预训练模型 | RoBERTa-wwm-ext | 0.743 | <b>0.748</b> | 0.754       |
|       | MacBERT         | 0.746 | 0.745        | 0.751       |




图 6: 欺诈类型多分类结果。准确率较二分类大幅回落, 且不同类型识别难度差异悬殊。

**现象分析:** 与二分类的近完美形成鲜明对比, 多分类的最优 Macro-F1 仅约 0.75, 任务难度显著提升, 从而有效拉开了模型差距: 具备深层语义建模能力的预训练模型 (RoBERTa/MacBERT) 与传统逻辑回归相当且略优, 而依赖局部 n-gram 的字符级 TextCNN 明显落后 (Macro-F1 仅 0.664)。这印证了“任务越难, 语义表示的价值越凸显”——在二分类的简单线索下各模型无从区分, 而在需要细粒度语义辨析的多分类任务上, 模型能力的层次才得以显现。

更具启发性的是**逐类 F1 的悬殊分化** (图 7)。投资诈骗 (F1≈0.98)、彩票诈骗 (F1≈0.9~1.0)、绑架诈骗 (F1≈0.90) 识别近乎完美, 因为它们各自携带**专属强特征** (“年化收益率/投资顾问”“中奖/兑奖”“人质/赎金”); 而钓鱼诈骗最难 (F1 仅 0.38~0.47), 身份盗窃次之 (F1 0.51~0.56, 且样本最少), 二者语义边界模糊、与其他类型交叉。混淆矩阵 (图 6b) 进一步显示: **客服诈骗与银行诈骗之间存在显著互相误判**——二者都以“账户异常、协助核验、退款返现”为话术骨架, 语义高度同质, 是拉低整体性能的主要来源。这说明欺诈类型的细分本质上是一个**语义密集型任务**, 远非关键词匹配可解, 为后续研究 (如引入类型层次结构、对长尾类别做数据增强) 留下了空间。




图 7: 各模型在每类欺诈类型上的 F1。带专属强特征的投资/彩票/绑架诈骗易于区分 (绿), 语义重叠的钓鱼诈骗、身份盗窃则难以识别 (红)。

#### 4.6 Fraud-R1 语义改写鲁棒性分析 (任务 b)

我们从测试集中抽取 400 条欺诈对话, 使用 DeepSeek 大模型按 §3.2.4 的八种策略分别改写 (每种 400 条, 共 2,000 条, 改写成功率 100%), 在**不重新训练**的前提下, 用已训练好的五个模型对改写样本进行预测。

**改写意图保留校验。**鲁棒性结论成立的前提是: 改写后的样本**仍然是欺诈**。若大模型在改写中无意削弱了诈骗意图, 检出率的下降便成为假象。为此, 我们引入一个**独立的 LLM 裁判** (脚本 `src/rewrite/verify_intent.py`), 对每种策略抽样 100 条改写样本二次判定其是否仍构成

诈骗。结果表明，八种策略的平均意图保留率高达 98.8%：诱导增强组（信任/紧迫/情感/权威）及谐音隐语均为 100%，关键的关键词规避为 98%，语义改写与良性伪装为 96%。这证实绝大多数改写样本确实保留了欺诈意图，**检出率的下降反映的是真实的鲁棒性失效，而非意图流失**，从而为后续结论提供了可信度保障。

表 6 汇总了各模型在不同策略下的欺诈检出率，图 8 与图 9 分别以热力图和下降柱状图可视化结果。为评估下降的统计显著性，我们对每个策略的检出率下降量 ( $\Delta DR$ ) 做 2,000 次**配对自助重采样 (bootstrap)**，给出 95% 置信区间；下表中标注的”\*”表示该下降在统计上显著 (CI 下界 > 0)。

表 6: 各模型在不同改写策略下的欺诈检出率 (%)。括号内为相对原始的下降 (攻击成功率, 百分点); 加粗为各模型最大下降项。所有对抗规避组的下降经 2,000 次配对 bootstrap 检验均统计显著 (95% CI 下界 > 0); 诱导增强组多数不显著。

| 模型        | 原始    | 诱导增强组 (对人) |       |       |       |      | 对抗规避组 (对检测器)       |                   |      |
|-----------|-------|------------|-------|-------|-------|------|--------------------|-------------------|------|
|           |       | 信任         | 紧迫    | 情感    | 权威    | 改写   | 规避                 | 良性伪装              | 谐音隐语 |
| TF-IDF+LR | 100.0 | 100.0      | 100.0 | 99.8  | 100.0 | 98.8 | <b>94.2</b> (5.8)  | 99.8              | 99.2 |
| TextCNN   | 100.0 | 100.0      | 100.0 | 100.0 | 100.0 | 98.2 | <b>93.0</b> (7.0)  | 97.8              | 98.8 |
| BiLSTM    | 99.8  | 98.2       | 99.8  | 99.8  | 100.0 | 97.2 | <b>86.2</b> (13.5) | 98.2              | 97.0 |
| RoBERTa   | 99.8  | 100.0      | 100.0 | 100.0 | 100.0 | 98.8 | 98.0               | <b>93.2</b> (6.5) | 94.0 |
| MacBERT   | 100.0 | 100.0      | 100.0 | 100.0 | 100.0 | 99.5 | 99.0               | 99.0              | 99.0 |




图 8: 各模型在不同改写策略下的欺诈检出率热力图。蓝色虚线左侧为诱导增强组, 右侧为对抗规避组。颜色越绿表示检出率越高 (越鲁棒), 越红表示越脆弱。






图 9: 不同策略导致的欺诈检出率下降 (攻击成功率)。诱导增强组几乎不造成下降, 对抗规避组 (尤其关键词规避) 造成显著下降。

#### 4.6.1 发现一: 诱导增强策略几乎不削弱检测器, 甚至适得其反

从表 6 左半部分可见, 信任建立、紧迫感、情感操纵、权威伪装四种诱导增强策略对各模型检出率的影响微乎其微 (普遍  $\leq 2.5$  个百分点), 多数情况下检出率维持在 99%~100%。对 RoBERTa, 这些策略甚至使检出率略有上升 (从 99.8% 升至 100.0%)。

这一反直觉现象可由**关键词密度**的变化来解释。如表 7 所示, 信任建立、紧迫感、权威伪装等策略在增强对人的说服力的同时, 显著**增加**了对话中欺诈关键词的数量 (从原始的 3.21 个/通增至 6.7~7.3 个/通)。这些新增的”立即””冻结””官方””验证”等词, 恰是检测器最敏感的判别特征——于是, 使话术对人更具迷惑性的修改, 反而使其对检测器更易暴露。这有力地验证了 §3.2.3 提出的**脆弱面正交性假设**: 社会工程诱导针对的是人类的认知与情感弱点, 而文本检测器作为冷静的旁观者并不受此影响。

表 7: 不同改写策略下的平均欺诈关键词密度 (个/通) 与平均长度 (字符)

|       | 原始   | 信任   | 紧迫   | 情感   | 权威   | 改写   | 规避          | 良性伪装 | 谐音隐语        |
|-------|------|------|------|------|------|------|-------------|------|-------------|
| 关键词密度 | 3.21 | 6.74 | 7.26 | 2.61 | 6.78 | 2.19 | <b>0.73</b> | 4.89 | <b>0.67</b> |
| 平均长度  | —    | 744  | 502  | 524  | 504  | 492  | 413         | 741  | 452         |

#### 4.6.2 发现二: 对抗规避策略才能真正击穿检测器

与诱导增强组形成鲜明对比, **对抗规避组**造成了显著的性能下降 (表 6 右半部分、图 9)。其中**关键词规避**策略威胁最大: 它在保留欺诈意图的前提下, 将关键词密度从 3.21 骤降至 0.73 (表 7), 致使 BiLSTM 检出率从 99.8% 跌至 86.2% (下降 **13.5** 个百分点, 95% bootstrap CI = [10.3, 17.0] 点, 显著远离 0), TextCNN 下降 7.0 点 (CI [4.8, 9.5]), TF-IDF+LR 下降 5.8 点 (CI [3.5, 8.0])。谐音隐语策略同样有效 (关键词密度降至 0.67), 对 RoBERTa 造成 5.8 点下降。良性伪装则对 RoBERTa 影响最大 (下降 6.5 点, CI [4.3, 8.8])——它用大段正常业务寒暄稀释诈骗信号, 扰乱了模型对整体语义的判断。相较之下, 诱导增强组的  $\Delta DR$  置信区间多数包含 0 (统计不显著), 从假设检验层面印证了二者的本质差异。

这表明, **真正威胁检测器的不是”对人更狠”的诱导, 而是”对机器更隐蔽”的规避**。这类攻击直接打击了检测器对表层特征的依赖, 印证了 §1.4 指出的”对表层词汇线索的过度依赖”这一核心局限, 也与 TextFooler [2] 等对抗攻击研究的结论一致。

4.6.3 发现三：模型鲁棒性呈现明显的代际分层

综合所有策略, 模型的鲁棒性排序为:MacBERT > RoBERTa > TF-IDF+LR ≈ TextCNN > BiLSTM。预训练语言模型展现出最强的鲁棒性——MacBERT 在所有策略下检出率均不低于 99.0%, 即便面对最强的关键词规避也仅下降 1.0 点; 这归功于其深层语义理解能力, 能够透过表层用词捕捉”诱导转账/索取信息”的深层欺诈意图。相比之下, 依赖局部 n-gram 与词频的浅层模型 (BiLSTM、TextCNN、TF-IDF) 在关键词被移除后性能明显滑坡。值得注意的是,RoBERTa 虽对关键词规避稳健, 却对良性伪装与谐音隐语相对敏感, 说明不同预训练模型存在差异化的脆弱面。

4.6.4 发现四：置信度比硬标签更早暴露鲁棒性裂缝

图 10 给出了各模型平均欺诈置信度随策略的变化。即使在检出率 (硬标签) 尚未明显下降的情况下, 预测置信度已先行松动。例如, 对抗规避使 TF-IDF+LR 的平均置信度从 0.991 降至 0.856,BiLSTM 从 0.997 降至 0.858; 语义改写、情感操纵亦使多数模型置信度下滑。这说明改写虽未必使样本越过 0.5 的决策阈值, 却已将其推近边界——在更严苛的阈值或噪声叠加下, 这些”勉强守住”的样本极可能失守。置信度因而是比准确率更敏感的鲁棒性探针。MacBERT 的置信度曲线最为平稳 (始终 ≥ 0.99), 再次印证其鲁棒性。




图 10: 各模型对欺诈样本的平均预测置信度随改写策略的变化。预训练模型曲线平稳, 浅层模型在对抗规避组下置信度明显下滑。

4.7 案例分析

为直观说明对抗规避的作用机制, 表 8 对比了同一条欺诈对话在关键词规避前后的片段。原文直白地出现”点击链接””验证码”等强信号, 改写后则代之以”我发个东西给你, 你点开按提示填””把那串数字念给我”等口语化、间接的表达——欺诈意图对人类而言依然清晰, 但供检测器捕捉的关键词几乎被清除, 从而成功规避了浅层模型的判别。

表 8: 关键词规避改写前后的对话片段对比 (节选)

| 版本    | 对话片段                                                                     |
|-------|--------------------------------------------------------------------------|
| 原始    | ……为了保证您的权益, 请您点击我们发送的链接, 按照提示操作即可完成退款<br>……需要您提供银行卡号和验证码。                |
| 关键词规避 | ……给我一些您的基本情况, 比如您那个卡上的号和我发过去的一串数字……我先加您微信, 然后发个小东西给您, 您点开它, 按上面的提示填一下就行。 |

**攻击成功样本的定量剖析。**为深入理解模型脆弱的机制，我们以最脆弱的 BiLSTM 为对象，统计被关键词规避成功翻转（原始判为欺诈、规避后误判为正常）的样本。在 400 条中共 **54 条被翻转**（脚本 `src/rewrite/error_analysis.py`），这些样本的平均关键词数由 3.74 骤降至 0.24，平均欺诈置信度由 0.998 暴跌至 0.105(图 11)。

更值得警惕的是，部分翻转样本**原本关键词数即为 0**，仅靠口语化改写就被击穿。例如一通投资诈骗，原文”我是天海投资咨询公司的投资顾问……年化收益率可以达到百分之二十”被改为”我是天海那边的，搞投资这块的……年化能到二十个点”，未删任何敏感词，却使 BiLSTM 的欺诈置信度从 0.9997 跌至 0.0407。这说明浅层模型不仅依赖关键词，还依赖**正式、书面化的话术句式**作为判别线索——一旦改写为随意的口语表达，即便语义未变，模型也会失守。这与 §4.4 的捷径诊断结论（模型部分依赖软性话术特征）相互印证。




图 11: 被关键词规避翻转的 54 个 BiLSTM 样本分析。左: 每条样本改写前后的欺诈置信度 (灰线连接), 规避后几乎全部跌破 0.5 决策线; 右: 翻转样本的关键词数从均值 3.74 降至 0.24。

## 4.8 TextFooler 自动化词级对抗攻击

§4.6 的 LLM 语义改写是**人工设计、语义级**的攻击。为从另一互补视角检验鲁棒性，本节实现经典的 **TextFooler** [2](AAAI 2020)——一种**自动化、词级、黑盒**的对抗攻击，它不依赖大模型，仅通过对分类器的查询反馈，贪心地以最少的同义词替换使预测翻转。这是 NLP 对抗鲁棒性领域的标准基线，可定量刻画”攻陷一个检测器需要多小的扰动、多少次查询”。

**中文离线适配。**原版 TextFooler 面向英文，依赖 counter-fitted 词向量、英文词性标注器与 Universal Sentence Encoder。由于 synonyms 等中文同义词库需付费授权且需联网，本文设计了一套**完全离线**的中文实现（脚本 `src/rewrite/textfooler_attack.py`），四步流程为：**(1)** 词重要性排序——jieba 分词后逐词删除，以目标类置信度的下降量对词排序（停用词与标点不参与）；**(2)** 候选生成——复用项目本地的原始 MacBERT 作**掩码语言模型**，将目标词掩码后取 top- $K$  ( $K=40$ ) 预测作为上下文同义候选（BERT-Attack [11] 式，比静态词典更贴合中文语境）；**(3)** 约束过滤——候选须与原词 jieba.posseg 词性一致，且替换后整句与原句的句向量余弦相似度  $\geq 0.7$ （用独立的 RoBERTa 编码，保证语义不漂移）；**(4)** 贪心替换——按重要性从高到低逐词替换为使欺诈概率下降最多的候选，一旦翻转即停。我们对 200 条欺诈对话发起攻击，以三项 TextFooler 标准指标评估：**攻击成功率 (ASR)**= 翻转成功数/原本分类正确数，**扰动率** = 成功样本平均（替换词数/总词数），**平均查询次数** = 每条样本对分类器的平均查询数。

表 9: TextFooler 词级对抗攻击结果 (200 条欺诈样本)。ASR 越高、攻击后准确率越低, 说明模型越脆弱; 扰动率/查询次数越低, 说明攻陷代价越小。

| 类别    | 模型        | ASR(%)↑     | 攻击后准确率 (%)  | 扰动率 (%)    | 平均查询数 |
|-------|-----------|-------------|-------------|------------|-------|
| 传统 ML | TF-IDF+LR | 47.5        | 52.5        | 14.0       | 717.6 |
|       | TextCNN   | 43.5        | 56.5        | 10.5       | 790.5 |
|       | BiLSTM    | <b>88.5</b> | <b>11.5</b> | <b>8.6</b> | 483.8 |
| 预训练模型 | RoBERTa   | <b>4.5</b>  | <b>95.5</b> | 4.6        | 740.9 |
|       | MacBERT   | 13.0        | 87.0        | 12.8       | 711.6 |




图 12: TextFooler 自动化词级对抗攻击结果。预训练模型 (RoBERTa/MacBERT) 鲁棒性远超浅层模型。

**结果分析。**表 9 与图 12 揭示了与 LLM 改写实验高度一致且更为极端的鲁棒性分层。**BiLSTM 最为脆弱**: 仅替换平均 8.6% 的词即可让 88.5% 的欺诈样本被误判为正常, 攻击后准确率从近 100% 暴跌至 11.5%——这意味着一个攻击者只需对话术做极小的同义改动, 就能近乎完全瓦解该检测器。传统 TF-IDF+LR 与 TextCNN 居中 (ASR 43~48%), 即近半样本可被攻陷。而**预训练语言模型展现出压倒性的鲁棒性**: RoBERTa 的 ASR 仅 4.5% (攻击后准确率仍高达 95.5%), MacBERT 为 13.0%, 即便消耗了与攻击浅层模型相当甚至更多的查询次数, 攻击者依然难以找到既保持语义、又能翻转预测的替换。

这一结果从**自动化对抗**的维度有力佐证了本文的核心论点: **依赖表层词汇统计的浅层模型在词级扰动下不堪一击, 而具备深层语义理解的预训练模型能透过同义替换把握不变的欺诈意图, 因而稳健得多**。TextFooler (自动词级) 与 §4.6 的 LLM 改写 (人工语义级) 两类攻击殊途同归, 共同指向同一鲁棒性排序: 预训练模型  $\gg$  浅层模型, 且 BiLSTM 始终是最脆弱的一环。两种攻击的交叉印证, 使本文关于模型鲁棒性分层的结论更具说服力。

## 4.9 讨论与启示

本文实验得出三点对反诈系统设计具有指导意义的启示:

1. **高准确率可能是“虚假的安全感”**。在词汇可分性强的数据集上, 简单模型即可达到近乎完美的精度, 但这并不代表真实鲁棒性。评估反诈模型时, 必须引入对抗改写测试, 否则会系统性高估其防护能力。
2. **应优先采用具备深层语义理解的预训练模型**。MacBERT/RoBERTa 在对抗规避下的稳健性显著优于浅层模型, 说明语义级建模是抵御关键词规避的有效途径。进一步地, 可引入对抗训练 [13]、数据增强等手段强化鲁棒性。
3. **防御重心应对准“规避”而非“诱导”**。本文发现表明, 检测器的脆弱性主要来自攻击者的特征隐藏行为 (谐音、隐语、良性伪装), 而非社会工程诱导本身。实战中应针对性地引入谐音归一化、隐语词典、语义意图识别等防御机制。



## 5 结论与展望

本文围绕欺诈通话检测与鲁棒性评估,完成了三项核心工作。其一,构建了横跨传统机器学习、深度学习与预训练语言模型三个代际、共五种结构的中文欺诈通话分类模型,实验表明各模型在原始**是否欺诈二分类**上均可达到约 0.999~1.000 的 F1,但这种高性能高度依赖表层欺诈关键词;为此本文进一步构建了**欺诈类型 7 分类**这一更具挑战性的任务(最优 Macro-F1 约 0.75),有效拉开了模型差距并揭示了类型间的语义混淆结构。其二,借鉴 Fraud-R1 的多策略增强思想,设计了诱导增强与对抗规避两组共八种 LLM 语义改写策略。其三,实现了 TextFooler 自动化词级对抗攻击(中文离线适配),从词级扰动维度与 LLM 改写交叉验证。后两者均在不重训的前提下系统评估了各模型的鲁棒性。

核心结论为:(1) 以提升对人说服力为目标的社会工程诱导策略(信任、紧迫、情感、权威)几乎不削弱检测器,甚至因关键词密度上升而更易被检出,揭示了社会工程脆弱面与文本检测脆弱面的**正交性**;(2) 真正击穿检测器的是以隐藏特征为目标的对抗规避策略,关键词规避使最脆弱的 BiLSTM 检出率下降达 13.5 个百分点(95% bootstrap CI [10.3, 17.0], 统计显著),TextFooler 仅替换 8.6% 的词即攻陷 88.5% 的 BiLSTM 样本;(3) 模型鲁棒性呈代际分层,具备深层语义理解的预训练模型(MacBERT、RoBERTa)远比浅层模型稳健——这一分层被 LLM 改写与 TextFooler 两类攻击**一致印证**(TextFooler 攻击下 RoBERTa 的 ASR 仅 4.5%,BiLSTM 达 88.5%);(4) 置信度是比硬标签更敏感的鲁棒性探针。上述结论建立在严格的可信度保障之上:捷径诊断排除了数据泄漏并量化了任务的真实难度,LLM 独立裁判确认改写样本的意图保留率达 98.8%,bootstrap 置信区间则从假设检验层面区分了显著与不显著的下降。

本研究亦存在局限:LLM 改写依赖单一模型,诱导增强组仍维持 400 条规模,TextFooler 评估采样 200 条;“对人更危险”这一论断主要承袭 Fraud-R1 的结论,本文未直接开展人类或 LLM 受害者实验予以验证。未来可引入多模型交叉改写、LLM-as-victim 的诱导有效性实验,并探索对抗训练、谐音归一化等防御方法,以及多轮对话级的动态攻防评测,进一步逼近真实反诈对抗场景。

## 代码与数据

本文的全部代码(数据预处理、五类模型训练、欺诈类型多分类、Fraud-R1 风格语义改写、TextFooler 词级对抗攻击、鲁棒性评估与可视化)、实验结果与运行截图均已开源,详见 GitHub 仓库:

<https://github.com/qiyueqiu/fraud-call-detection>

## References

- [1] Shu Yang, Shenzhe Zhu, Zeyu Wu, Keyu Wang, Junchi Yao, Junchao Wu, Lijie Hu, Mengdi Li, Derek F. Wong, and Di Wang. Fraud-R1: A multi-round benchmark for assessing the robustness of LLM against augmented fraud and phishing inducements. *Findings of the Association for Computational Linguistics: ACL 2025*, 2025. URL <https://arxiv.org/abs/2502.12904>. arXiv:2502.12904.
- [2] Di Jin, Zhijing Jin, Joey Tianyi Zhou, and Peter Szolovits. Is BERT really robust? a strong baseline for natural language attack on text classification and entailment. In *Proceedings of the AAAI Conference on Artificial Intelligence*, volume 34, pages 8018–8025, 2020. URL <https://ojs.aaai.org/index.php/AAAI/article/view/6311>.
- [3] Anusuya Krishnan. Exploring machine learning and transformer-based approaches for deceptive text classification. *arXiv preprint arXiv:2308.05476*, 2023. URL <https://arxiv.org/abs/2308.05476>.
- [4] Rathnakar Achary, Sai Nithin Bugath, G. Chakrapani, and M. Venkatesh. Enhanced phishing detection using LSTM, CNN, and SVM techniques. In *Lecture Notes in Networks and Systems, Springer*, pages 185–204, 2025. doi: 10.1007/978-981-96-4148-2\_16. URL [https://link.springer.com/chapter/10.1007/978-981-96-4148-2\\_16](https://link.springer.com/chapter/10.1007/978-981-96-4148-2_16).

- [5] Abhiram Natarajan, Anirudh Kannan, Varun Belagali, Vaibhavi N. Pai, Rajashree Shettar, and Poonam Ghuli. Spam detection over call transcript using deep learning. In *Lecture Notes in Networks and Systems*, Springer, pages 138–150, 2021. doi: 10.1007/978-3-030-89880-9\_10. URL [https://link.springer.com/chapter/10.1007/978-3-030-89880-9\\_10](https://link.springer.com/chapter/10.1007/978-3-030-89880-9_10).
- [6] Jacob Devlin, Ming-Wei Chang, Kenton Lee, and Kristina Toutanova. BERT: Pre-training of deep bidirectional transformers for language understanding. In *Proceedings of NAACL-HLT 2019*, pages 4171–4186, 2019. URL <https://aclanthology.org/N19-1423/>.
- [7] Yinhan Liu, Myle Ott, Naman Goyal, Jingfei Du, Mandar Joshi, Danqi Chen, Omer Levy, Mike Lewis, Luke Zettlemoyer, and Veselin Stoyanov. RoBERTa: A robustly optimized BERT pretraining approach. *arXiv preprint arXiv:1907.11692*, 2019. URL <https://arxiv.org/abs/1907.11692>.
- [8] Yiming Cui, Wanxiang Che, Ting Liu, Bing Qin, Shijin Wang, and Guoping Hu. Re-visiting pre-trained models for Chinese natural language processing. In *Findings of the Association for Computational Linguistics: EMNLP 2020*, pages 657–668, 2020. URL <https://aclanthology.org/2020.findings-emnlp.58/>.
- [9] Mariam Ibrahim and Ruba Elhafiz. Phishing email detection using BERT and RoBERTa. *Computation*, 14(2):46, 2026. URL <https://www.mdpi.com/2079-3197/14/2/46>.
- [10] Yi Zeng, Hongpeng Lin, Jingwen Zhang, Diyi Yang, Ruoxi Jia, and Weiyan Shi. How Johnny can persuade LLMs to jailbreak them: Rethinking persuasion to challenge AI safety by humanizing LLMs. In *Proceedings of the 62nd Annual Meeting of the Association for Computational Linguistics (Volume 1: Long Papers)*, pages 14322–14350, 2024. URL <https://aclanthology.org/2024.acl-long.773>.
- [11] Linyang Li, Ruotian Ma, Qipeng Guo, Xiangyang Xue, and Xipeng Qiu. BERT-ATTACK: Adversarial attack against BERT using BERT. In *Proceedings of EMNLP 2020*, pages 6193–6202, 2020. URL <https://aclanthology.org/2020.emnlp-main.500/>.
- [12] Guangyu Zheng, Tingting He, Zhenyu Wang, and Haochang Wang. System report for CCL23-Eval task 6: A method for telecom network fraud case classification based on two-stage training framework and within-task pretraining. In *Proceedings of the 22nd Chinese National Conference on Computational Linguistics (Volume 3: Evaluations)*, pages 206–212, 2023. URL <https://aclanthology.org/2023.ccl-3.23>.
- [13] Zhuoxian Liu, Tuo Shi, and Xiaofeng Hu. A text classification model combining adversarial training with pre-trained language model and neural networks: A case study on telecom fraud incident texts. *arXiv preprint arXiv:2411.06772*, 2024. URL <https://arxiv.org/abs/2411.06772>.
- [14] Het Patel, Umair Rehman, and Farkhund Iqbal. Evaluating the efficacy of large language models in identifying phishing attempts. *arXiv preprint arXiv:2404.15485*, 2024. URL <https://arxiv.org/abs/2404.15485>.
- [15] Jianpeng Ding and Houpan Zhou. Telecom fraud detection based on large language models: A multi-role, multi-layer prompting strategy. *Applied Sciences*, 16(1):544, 2026. URL <https://www.mdpi.com/2076-3417/16/1/544>.
- [16] Zitong Shen, Sineng Yan, Youqian Zhang, Xiapu Luo, Grace Ngai, and Eugene Yujun Fu. Exploring LLM-based real-time detection of phone scams. *arXiv preprint arXiv:2502.03964*, 2025. URL <https://arxiv.org/abs/2502.03964>.
- [17] Kaijie Zhu, Jindong Wang, Jiaheng Zhou, Zichen Wang, Hao Chen, Yidong Wang, Linyi Yang, Wei Ye, Yue Zhang, Neil Zhenqiang Gong, and Xing Xie. PromptRobust: Towards evaluating the robustness of large language models on adversarial prompts. *arXiv preprint arXiv:2306.04528*, 2023. URL <https://arxiv.org/abs/2306.04528>.
- [18] Boxin Wang, Chejian Xu, Shuohang Wang, Zhe Gan, Yu Cheng, Jianfeng Gao, Ahmed Hassan Awadallah, and Bo Li. Adversarial GLUE: A multi-task benchmark for robustness evaluation of language models. In *NeurIPS 2021 Datasets and Benchmarks Track*, 2021.

- URL <https://arxiv.org/abs/2111.02840>. arXiv:2111.02840.
- [19] John X. Morris, Eli Lifland, Jin Yong Yoo, Jake Grigsby, Di Jin, and Yanjun Qi. TextAttack: A framework for adversarial attacks, data augmentation, and adversarial training in NLP. In *Proceedings of EMNLP 2020: System Demonstrations*, pages 119–126, 2020. URL <https://aclanthology.org/2020.emnlp-demos.16/>.
- [20] Yize Cheng, Vinu Sankar Sadasivan, Mehrdad Saberi, Shoumik Saha, and Soheil Feizi. Adversarial paraphrasing: A universal attack for humanizing AI-generated text. *arXiv preprint arXiv:2506.07001*, 2025. URL <https://arxiv.org/abs/2506.07001>.
- [21] Zhiming Ma, Peidong Wang, Minhua Huang, Jingpeng Wang, Kai Wu, Xiangzhao Lv, Yachun Pang, Yin Yang, Wenjie Tang, and Yuchen Kang. TeleAntiFraud-28k: An audio-text slow-thinking dataset for telecom fraud detection. *arXiv preprint arXiv:2503.24115*, 2025. URL <https://arxiv.org/abs/2503.24115>.